

高斯混合模型

Gaussian mixture model(GMM)
learning note For reading translation

我真的不懂忧郁



高斯混合模型

Gaussian mixture model(GMM)
learning note For reading translation

by

我真的不懂忧郁

Student Name	Student Number
First Surname	1234567

Instructor:	I. Surname
Teaching Assistant:	I. Surname
Project Duration:	Month, Year - Month, Year
Faculty:	Faculty of Aerospace Engineering, Delft

Cover: Canadarm 2 Robotic Arm Grapples SpaceX Dragon by NASA under
CC BY-NC 2.0 (Modified)

Style: TU Delft Report Style, with modifications by Daan Zwaneveld

Preface

A preface...

我真的不懂忧郁
Delft, May 2024

Summary

A summary...

目录

Preface	i
Summary	ii
Nomenclature	iv
1 高斯分布	1
2 Gaussian mixture model	
高斯混合模型概述	2
2.1 从几何的角度	2
2.2 从混合模型的角度	2
3 高斯混合模型的参数估计:	
极大似然估计	4
3.1 极大似然估计 (maximum likelihood estimation)	4
3.2 极大似然估计看高斯混合模型	5
4 高斯混合模型的参数估计:	
EM 求解	6
4.1 E-step	6
4.2 M-step	7
References	8
A Source Code Example	9
B Task Division Example	10

Nomenclature

If a nomenclature is required, a simple template can be found below for convenience. Feel free to use, adapt or completely remove.

Abbreviations

Abbreviation	Definition
ISA	International Standard Atmosphere
...	

Symbols

Symbol	Definition	Unit
V	Velocity	[m/s]
...		
ρ	Density	[kg/m ³]
...		

Chapter 1

高斯分布

目录大纲以维基百科为准

Chapter 2

Gaussian mixture model

高斯混合模型概述

高斯混合模型 (*Gaussian Mixture Model, GMM*) 是一种流行的概率模型，用于表示具有多个子高斯分布的混合分布。它常用于聚类、分类和密度估计。下面我们从混合模型的角度详细讨论高斯混合模型。

高斯混合模型是一种混合模型，其中每个组件都是一个高斯分布。混合模型的基本思想是将数据视为由若干个子分布生成，每个子分布代表一个不同的群体或类别。

一个 GMM 可以表示为

$$p(x) = \sum_{i=1}^K \pi_k \mathcal{N}(x_k | \mu_k, \Sigma_k) \quad (2.1)$$

其中 K 是高斯分布的数量， π_k 是第 k 个高斯分布的混合系数，表示该高斯分布的权重，满足

$$\sum_{i=1}^K \pi_k = 1 \quad (2.2)$$

$\mathcal{N}(x_k | \mu_k, \Sigma_k)$ 是第 k 个高斯分布，其均值为 μ_k ，协方差矩阵为 Σ_k 。

2.1. 从几何的角度

几何角度来看就是多个高斯分布加权平均叠加而成的。

2.2. 从混合模型的角度

由于是多个高斯分布的混叠，所以我们可以用两个随机变量 X, Z ， X 称为 *observed variable*， Z 称为 *latent variable*，即对应哪个高斯分布的随机变量。例如一共有 c_1, \dots, c_n 个高斯分布。

Z	c ₁	c ₂	...	c _k
x	p ₁	p ₂	...	p _k

表 2.1: 概率分布

则观测随机变量总的概率分布为

$$\begin{aligned} P(X) &= \sum_Z P(X, Z) \\ &= \sum_{k=1}^K P(X, Z = C_k) \\ &= \sum_{k=1}^K P(Z = C_k) \cdot P(X|Z = C_k) \\ &= \sum_{k=1}^K p_k \cdot \mathcal{N}(X|\mu_k, \Sigma_k) \end{aligned}$$

(2.3)

Chapter 3

高斯混合模型的参数估计: 极大似然估计

3.1. 极大似然估计 (maximum likelihood estimation)

给定概率分布 D ，已知其概率密度函数（连续分布）或者概率质量函数（离散分布）为 f_D ，以及一个分布参数 θ ，我们可以从这个分布中抽一个具有 n 个值的采样 X_1, X_2, \dots, X_n ，利用 f_D 计算出其似然函数

$$L(\theta|x_1, \dots, x_n) = f_\theta(x_1, \dots, x_n) \quad (3.1)$$

若 D 是离散分布， f_θ 即是在参数为 θ 时观测到这一采样的概率；若其是连续分布， f_θ 则为 X_1, X_2, \dots, X_n 联合分布的概率密度函数在观测值处的取值。

从数学上来说，我们可以在 θ 的所有可能取值中寻找一个值使得似然函数取到最大值。这个使可能性最大的 $\hat{\theta}$ 值即称为 θ 的最大似然估计。由定义，最大似然估计是样本的函数。

相对熵

最大似然估计可以从相对熵推导而来。相对熵衡量了使用一个给定分布 Q 来近似另一个分布 P 时的信息损失，对于离散随机变量

$$D_{KL}(P||Q) = \sum_i P(i) \log \frac{P(i)}{Q(i)} \quad (3.2)$$

其中 P 是真实分布， Q 是近似分布。在最大似然估计的情景下，假设分布拥有一系列参数 θ ，我们希望通过样本得到参数的估计值 $\hat{\theta}$ ，我们可以利用相对熵来评估估计的好坏

$$D_{KL}(p_\theta(x)||p_{\hat{\theta}}(x)) = \sum_{x \in E} p_\theta(x) \log \frac{p_\theta(x)}{p_{\hat{\theta}}(x)} \quad (3.3)$$

根据数学期望的定义，上式可以改写

$$D_{KL}(p_\theta(x)||p_{\hat{\theta}}(x)) = \mathbb{E}_\theta[\log \frac{p_\theta(x)}{p_{\hat{\theta}}(x)}] = \mathbb{E}_\theta[\log p_\theta(x)] - \mathbb{E}_\theta[\log p_{\hat{\theta}}(x)] \quad (3.4)$$

KL 值越大，参数估计越坏，因此，需要通过改变估计参数 $\hat{\theta}$ 的值来获得最小的值，所对应的参数极为最佳估计参数

$$\hat{\theta}_{best} = \arg \min_{\hat{\theta}} D_{KL}(p_{\theta}(x)||p_{\hat{\theta}}(x)) \quad (3.5)$$

假设有 n 个样本，根据大数定律，

$$\mathbb{E}_{\theta}[\log p_{\hat{\theta}(x)}] \rightsquigarrow \frac{1}{n} \sum_{i=1}^n \log p_{\hat{\theta}}(x_i) \quad (3.6)$$

因此我们可以通过下式去估计

$$D_{KL}(p_{\theta}(x)||p_{\hat{\theta}}(x)) = \mathbb{E}_{\theta}[\log p_{\hat{\theta}(x)}] - \frac{1}{n} \sum_{i=1}^n \log p_{\hat{\theta}}(x_i) \quad (3.7)$$

对于一个已知的分布，其参数 θ 是确定的。因此， $\mathbb{E}_{\theta}[\log p_{\hat{\theta}(x)}]$ 为常数。因此，我们可以通过最小化 KL 值获得最佳估计参数：

$$\hat{\theta} = \arg \min_{\theta} \mathbb{E}_{\theta}[\log p_{\hat{\theta}(x)}] - \frac{1}{n} \sum_{i=1}^n \log p_{\hat{\theta}}(x_i) \quad (3.8)$$

只要求和项最大，那么整体就最小，这个优化问题等价于

$$\begin{aligned} & \arg \max_{\theta} \frac{1}{n} \sum_{i=1}^n \log p_{\hat{\theta}}(x_i) \\ & \Rightarrow \arg \max_{\theta} \log \left[\prod_{i=1}^n p_{\hat{\theta}}(x_i) \right] \\ & \Rightarrow \arg \max_{\theta} \prod_{i=1}^n p_{\hat{\theta}}(x_i) \end{aligned} \quad (3.9)$$

因此，要得到最佳参数估计值，只需要最大化 $\prod_{i=1}^n p_{\hat{\theta}}(x_i)$ ，这就是最大似然函数。

3.2. 极大似然估计看高斯混合模型

极大似然估计来解单一高斯问题是存在解析解的，但是实际上极大似然估计来看高斯混合模型的解析解是求不出来的。这一节主要是为了看一下为什么。

设

$$X : \text{Observed Data} \rightarrow X = (x_1, x_2, \dots, x_n) \quad (3.10)$$

$$(X, Z) : \text{Complete Data} \quad (3.11)$$

$$\theta : \text{Parameter} \rightarrow \theta = \{p_1, \dots, p_k, \mu_1, \dots, \mu_k, \sum_1, \dots, \sum_k\} \quad (3.12)$$

极大似然估计去估计参数

$$\begin{aligned} \hat{\theta}_{MLE} &= \arg \max_{\theta} \log P(X) \\ &= \arg \max_{\theta} \log \prod_{i=1}^N P(x_i) \\ &= \arg \max_{\theta} \sum_{i=1}^N \log P(x_i) \end{aligned} \quad (3.13)$$

Chapter 4

高斯混合模型的参数估计: EM 求解

EM 其实是期望最大算法。

4.1. E-step

$$\begin{aligned} Q(\theta, \theta^{(t)}) &= \int_x \log P(x, z|\theta) \cdot P(z|x, \theta^{(t)}) dz \\ &= \sum_{i=1}^N \sum_{z_i} \log [P_{z_1} \cdot \mathcal{N}(x_i|\mu_{z_i}, \Sigma_{z_i})] \cdot \frac{p_{z_i} \cdot \mathcal{N}(x_i|\mu_{z_i}^{(t)}, \Sigma_{z_i}^{(t)})}{\sum_{k=1}^K p_k^{(t)} \cdot \mathcal{N}(x_i|\mu_{z_i}^{(t)}, \Sigma_{z_i}^{(t)})} \\ &= \sum_{i=1}^N \sum_{z_i} \log [P_{z_1} \cdot \mathcal{N}(x_i|\mu_{z_i}, \Sigma_{z_i})] \cdot P(z_i|x_i, \theta^{(t)}) \\ &= \sum_{i=1}^N \sum_{z_i} \log [P_{z_1} \cdot \mathcal{N}(x_i|\mu_{z_i}, \Sigma_{z_i})] \cdot P(z_i = c_k|x_i, \theta^{(t)}) \\ &= \sum_{i=1}^N \sum_{z_i} [\log P_{z_1} + \log \mathcal{N}(x_i|\mu_{z_i}, \Sigma_{z_i})] \cdot P(z_i = c_k|x_i, \theta^{(t)}) \end{aligned} \quad (4.1)$$

转化为最优化问题

$$\theta^{(t+1)} = \arg \max_{\theta} Q(\theta, \theta^{(t)}) \quad (4.2)$$

求 $p_k^{(t+1)}$

$$\left\{ \begin{array}{l} p_k^{(t+1)} = \arg \max_{p_k} \sum_{k=1}^K \sum_{i=1}^N \log p_k \cdot P(z_i = c_k|x_i, \theta^{(t)}) \\ s.t. \quad \sum_{k=1}^K p_k = 1 \end{array} \right. \quad (4.3)$$

4.2. M-step

求 $p^{(t+1)} = (p_1^{(t+1)}, p_2^{(t+1)}, \dots, p_k^{(t+1)})$,

$$\begin{cases} \max_p \sum_{k=1}^K \sum_{i=1}^N \log p_k \cdot P(z_i = c_k | x_i, \theta^{(t)}) \\ s.t. \sum_{k=1}^K p_k = 1 \end{cases} \quad (4.4)$$

由拉格朗日乘子法，结论是

$$p_k^{(t+1)} = \frac{1}{N} \sum_{i=1}^N P(z_i = c_k | x_i, \theta^{(t)}) \quad (4.5)$$

References

- [1] I. Surname, I. Surname, and I. Surname. “The Title of the Article”. In: *The Title of the Journal* 1.2 (2000), pp. 123–456.

Chapter A

Source Code Example

Adding source code to your report/thesis is supported with the package listings. An example can be found below. Files can be added using `\lstinputlisting[language=<language>]{<filename>}`.

```
1 """
2 ISA Calculator: import the function, specify the height and it will return a
3 list in the following format: [Temperature,Density,Pressure,Speed of Sound].
4 Note that there is no check to see if the maximum altitude is reached.
5 """
6
7 import math
8 g0 = 9.80665
9 R = 287.0
10 layer1 = [0, 288.15, 101325.0]
11 alt = [0,11000,20000,32000,47000,51000,71000,86000]
12 a = [-.0065,0,.0010,.0028,0,-.0028,-.0020]
13
14 def atmosphere(h):
15     for i in range(0,len(alt)-1):
16         if h >= alt[i]:
17             layer0 = layer1[:]
18             layer1[0] = min(h,alt[i+1])
19             if a[i] != 0:
20                 layer1[1] = layer0[1] + a[i]*(layer1[0]-layer0[0])
21                 layer1[2] = layer0[2] * (layer1[1]/layer0[1])**(-g0/(a[i]*R))
22             else:
23                 layer1[2] = layer0[2]*math.exp((-g0/(R*layer1[1]))*(layer1[0]-layer0[0]))
24     return [layer1[1],layer1[2]/(R*layer1[1]),layer1[2],math.sqrt(1.4*R*layer1[1])]
```

Chapter B

Task Division Example

If a task division is required, a simple template can be found below for convenience. Feel free to use, adapt or completely remove.

表 B.1: Distribution of the workload

Task	Student Name(s)
Summary	
Chapter 1 Introduction	
Chapter 2	
Chapter 3	
Chapter *	
Chapter * Conclusion	
Editors	
CAD and Figures	
Document Design and Layout	